


Losowo wygenerowane przykładowe dane z podziałem na klasy dla których przeprowadzono eksperyment, polegający na podziale próbek na testujące i uczące, a następnie testowaniu działania algorytmów 100 razy i poddawaniu wyników różnym miarom jakości klasyfikacji




W ostatniej iteracji eksperymentu przeprowadzono szereg wizualizacji:

Wykres 1: Od lewej: Wyniki oczekiwane, Wyniki zwrócone w wyniku działania algorytmu, błędy klasyfikacji


Wykres 2: Krzywa ROC wraz z wartością współczynnika AUC

Wykres 3: Krzywa dyskryminacyjna


naivebayes.GaussianNB



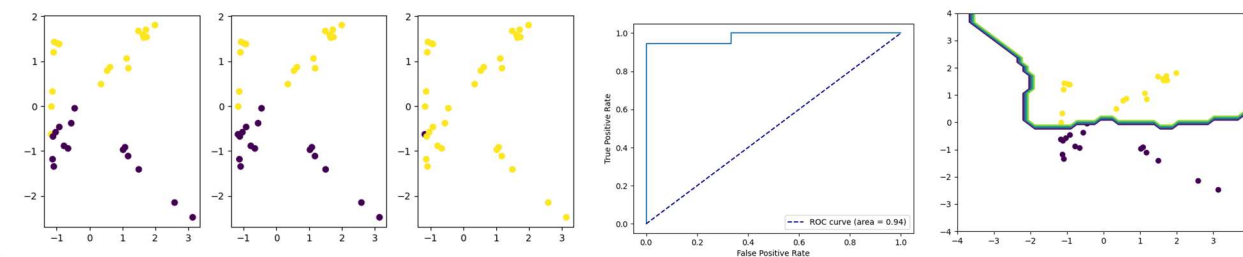
QuadraticDiscriminantAnalysis




KNeighborsClassifier




SVC



DecisionTreeClassifier



Podsumowanie wyników(wykres oraz tabela ze średnimi wartościami stu iteracji przeprowadzonego eksperymentu, czas podany w sekundach*500, w celu lepszego ukazania skali)



testTi...	trainT...	roc_auc	f1_sco...	precis...	recall...	accura...
0.042616...	0.317353...	0.881718...	0.881894...	0.890589...	0.880660...	0.882121...
0.143809...	0.190852...	0.891456...	0.891985...	0.897298...	0.893292...	0.891515...
0.880340...	0.186307...	0.940860...	0.942810...	0.921432...	0.968563...	0.941212...
0.159626...	0.662490...	0.937228...	0.940593...	0.911295...	0.974519...	0.938181...
0.083955...	0.267782...	0.863123...	0.862191...	0.875137...	0.860003...	0.862727...

Wnioski:

- Wszystkie algorytmy działają z podobną dokładnością, precyzją i czułością, osiągają podobny współczynnik f1 i krzywą pod wykresem roc.
- Nieznacznie ponad przeciętną dokładności, precyzji, czułości, współczynnika f1 wyszły algorytmy SVC i KNeighborsClassifier
- Algorytm KNeighborsClassifier cechuje się zdecydowanie największym czasem testowania, reszta algorytmów nie odbiega znacząco od siebie czasami testowania.
- Algorytm SVC cechuje się zdecydowanie największym czasem uczenia, reszta algorytmów nie odbiega znacząco od siebie czasami uczenia.
- Krzywa ROC pozwala ocenić poprawność klasyfikatora poprzez jego miary czułości i specyficzności. Po zobrazowaniu jej w sposób podobny do widocznego wyżej, można ocenić poprawność poprzez to, jak bardzo jest ona oddalona od przerywanej kreski obrazującej model losowy(czym wyżej na wykresie tym lepiej).
- Pole pod krzywą AUC pozwala określić poprawność klasyfikatora(czym bliżej wartości 1 tym lepiej)